

El estudio computacional de la ansiedad con un algoritmo de Inteligencia Artificial

Muñiz-Jiménez, Alicia¹

¹ Departamento de las Ciencias Cognitivas y del Comportamiento, Facultad de Psicología, Universidad Nacional Autónoma de México.

Abstract

Los algoritmos computacionales y el uso de la Inteligencia Artificial están comenzando a incursionar en el campo de la psicología clínica para dar explicación a los mecanismos detrás de las enfermedades mentales. La ansiedad al ser uno de los desórdenes mentales con mayor prevalencia en el mundo recibe mucha investigación, sin embargo, todavía no se entiende del todo cómo el pesimismo y el nivel de aversión en el ambiente impactan en el desarrollo de la sintomatología ansiosa. Por ello, se implementó el de aprendizaje por reforzamiento en el entorno four_rooms de la paquetería neuronav y se encontró que la cantidad de exploración es un factor determinante para la magnificación de los síntomas de un agente pesimista en un entorno con un nivel elevado de aversión. Además, se corroboró que el nivel de pesimismo genera menor control cognitivo, una mayor evitación, la propagación de una errónea evaluación de diversos estados en el entorno y la sobreexplotación de estados conocidos.

Keywords: *ansiedad; pesimismo; control cognitivo; Inteligencia Artificial; aprendizaje por reforzamiento.*

1. Introducción

Diversas investigaciones indican que la ansiedad sesga múltiples procesos cognitivos, incluyendo el control cognitivo, lo cual ocurre en parte porque la ansiedad conlleva a un excesivo procesamiento de los estímulos amenazantes, impactando el cómo las personas ven y responden a su ambiente (Grant y White, 2016). Además,

los desórdenes de ansiedad son uno de los más prevalentes en la clase de las enfermedades mentales y por ende es de gran importancia entender a profundidad el mecanismo detrás de esta y cuál sería la forma más eficiente de tratarla (Remes, Brayne, Van der Linde y Lafortune, 2016).

Por otro lado, es bien conocido que muchos estudios sobre la ansiedad toman una perspectiva clínica, pero pocas son las investigaciones que tratan de implementar modelos computacionales. Como resultado, el objetivo de este artículo es mostrar los avances más recientes en el área con la inclusión de modelos bayesianos, de aprendizaje por reforzamiento y modelos matemáticos en las neurociencias que van más allá de una simple regresión lineal, los cuales en conjunto ayudan a comprender mejor el estudio de la ansiedad. Finalmente, se implementará el modelo propuesto por Zorowitz, Momennejad y Daw (2020) sobre los experimentos de optimismo y pesimismo en la ansiedad, para así evaluar cómo afecta esto en un entorno más complejo que el utilizado en el artículo de los autores. Esto como un primer acercamiento al modelo y la implementación de la Inteligencia Artificial en la psiquiatría computacional, buscando dar respuesta a cómo la cantidad de exploración y el nivel de un estado aversivo impacta en el control cognitivo y la toma de decisiones de un agente pesimista.

2. Entendiendo el control cognitivo y su relación con el aprendizaje

Para poder identificar las diferencias entre las personas sanas y las personas con ansiedad en su manejo del control cognitivo y su impacto en el aprendizaje, en este apartado se profundizará en qué es el control cognitivo y los principales factores que lo modifican.

El control cognitivo es la habilidad de desempeñar conductas orientadas a metas, incluso ante la competencia de comportamientos habituales o que son más convincentes de forma inmediata (Cohen, 2017). Por ello, el control cognitivo está estrechamente relacionado con la flexibilidad cognitiva, la cual es la habilidad de ajus-

tar el comportamiento de uno mismo ante cambios en las demandas del ambiente (Kraft, Rademacher, Eckart y Fiebach, 2020). En particular, el control cognitivo es visto como una forma de toma de decisiones jerárquicamente superior, donde el nivel inferior de la toma de decisiones se encarga de elegir u optimizar las acciones y el nivel superior se avoca a optimizar los procesos cognitivos del cerebro (Verguts, 2017). No obstante, ambos niveles usan la misma maquinaria para la toma de decisiones y son tres los marcos de modelamiento más influyentes que se han usado para desarrollar modelos computacionales de control cognitivo: el procesamiento paralelo distribuido, el aprendizaje por reforzamiento y la inferencia bayesiana (Verguts, 2017).

Por mucho tiempo se creyó que el control cognitivo operaba como un sistema de competencia y compensación entre los extremos de la estabilidad y la flexibilidad cognitiva, donde mayor flexibilidad implicaba menor estabilidad y viceversa (Van Stockum y De Caro, 2020). Empero, una investigación reciente de Gedder y Egner (2022) ha demostrado que ajustes estratégicos en la estabilidad tienen poca influencia en la flexibilidad, así como al contrario, dando a entender que estas funciones se pueden regular de forma independiente y que se puede ser estable y flexible a la vez. Si bien todavía no se tiene una respuesta clara de lo que determina el balance óptimo entre ambas funciones, es importante entender qué factores influyen a la estabilidad y a la flexibilidad de forma independiente.

El gran interés en la flexibilidad cognitiva surge por querer comprender la habilidad de poder romper esquemas mentales preestablecidos, así como el aprender con pocas o incluso una sola experiencia, es decir, poder adaptarse a diferentes entornos o a entornos cambiantes. Sin embargo, no es hasta que se comienza a estudiar las funciones cognitivas de manera multifacética que se descubre el impacto de ciertas funciones en la flexibilidad cognitiva. Por ejemplo, la importancia del control atencional para establecer esquemas mentales y que personas con una mayor memoria primaria son más propensas a romper esquemas mentales, es decir, demuestran una

mayor flexibilidad cognitiva (Van Stockum et al., 2020). En comparación, las personas con mayor memoria secundaria son menos probables a romper un esquema mental debido a una mayor habilidad para recuperar efectivamente estrategias usadas con anterioridad vía la memoria secundaria, lo cual promueve un uso persistente de esas estrategias y puede derivar en rigidez cognitiva cuando las pistas de recuperación automática recuperan información errónea (Van Stockum et al., 2020). Por otro lado, se sabe que la baja o alta volatilidad del ambiente requiere poca o alta flexibilidad cognitiva, respectivamente, así como que la previa exposición a ambientes con alta volatilidad permite una adaptación más rápida a los cambios en las reglas de ambientes subsecuentes, es decir, existe la transferencia en las expectativas de las demandas de la flexibilidad cognitiva para guiar el control cognitivo en diferentes entornos (Wen, Geddert, Madlon-Kay y Egner, 2021).

3. Los avances más recientes en la ansiedad debido a los modelos computacionales

Mientras que algunos científicos argumentan que los modelos neurobiológicos son suficientes para entender la mente, en realidad lo que se necesita es hacer también una aproximación computacional para formalizar cómo las funciones psicológicas trabajan (Sharp y Eldar, 2019). La psiquiatría computacional ya está haciendo esto al tratar de entender la relación entre la neurobiología, el ambiente y los síntomas mentales en términos computacionales (Adams, Huys y Roiser, 2016). Pero es necesario que los científicos estén dispuestos a ir más allá y aprender nuevas herramientas de análisis para lograrlo y no lo haga solo un grupo reducido de investigadores.

Desde las neurociencias un gran reto es entender las dinámicas cerebrales y para ello es necesario ver más allá de las correlaciones estadísticas con métodos lineales, ya que el cerebro no opera solo de forma lineal. Un estudio con EEG sobre las dinámicas temporales de los microestados en sujetos con desórdenes de ansiedad y sanos, tomaron el método de von Wegner, Tagliazucchi y Laufs (2017) donde tratan de forma independiente a los microestados como parte de un proceso estocástico discreto y analizan las dependencias temporales en la secuencia de los microestados.

En esta investigación no encontraron diferencias en la topografía de los microestados, dando a entender que no existe un cambio significativo entre las estructuras críticas de las personas con ansiedad y las personas control, pero sí encontraron diferencias entre las dinámicas de la red neuronal entre los grupos: una de las más relevante fue que el grupo de las personas de ansiedad exhibió mayores propiedades de simetría y estacionariedad, dando a entender que tiene una menor dinámica al cambiar entre estados cerebrales (Al Zoubi, Mayeli, Tsuchiyagaito, Misaki, Zotev, Refai, Paulus, Bodurka y the Tulsa 1000 Investigators, 2019). Esto posiblemente puede estar correlacionado con el hecho de que las personas con ansiedad muestren un menor comportamiento flexible al tratar de adaptarse a un ambiente con demandas cambiantes, aunque mayor investigación necesita ser realizada para esclarecerlo (Wilson, Nusbaum, Whitney y Hinson, 2018).

Por otro lado, los modelos bayesianos han contribuido a entender cómo es el aprendizaje en personas con ansiedad. Por ejemplo, un modelo bayesiano fue el primer modelo computacional en proporcionar evidencia del fallo existente en la adaptación de la precisión interoceptiva para las persona que tiene ansiedad, depresión, problemas alimenticios y/o abuso de sustancias (Smith, Kuplicki, Feinstein, Forthman, Stewart, Tulsa 1000 investigators y Sahib, 2020). Esto se considera importante seguir estudiándolo para ver cómo afecta a la regulación interna y la toma de decisiones guiada por la interocepción (Smith et al., 2020).

También, al nivel de interacción social un modelo bayesiano permitió describir como las personas con ansiedad sobreinvierten en parejas explotativas, dejando claro que existe una reducción en el aprendizaje de eventos sociales negativos y un fallo en mejorar el aprendizaje cuando la incertidumbre incrementa, en comparación de sujetos sanos que pueden identificar cuándo dejar de invertir en una pareja social que los explota (Lamba, Frank y FerlmanHall, 2020). Esto puede parecer sorprendente en el sentido de que las personas con ansiedad a nivel individual, no al nivel de interacción social, tienden a tener un parámetro de aprendizaje con valores elevados

para los castigos o los reforzamientos negativos y valores reducidos para las recompensas en los modelos de aprendizaje por refrozamiento, es decir, son muy rápidos para actualizar su conducta ante resultados negativos (Pike y Robinson, 2022).

Finalmente, un modelo de inferencia y aprendizaje bayesiano jerárquico explica como los estados de ansiedad están asociados con la subestimación de la incertidumbre ambiental y la incertidumbre en la información de la tendencia de las recompensas, así como que se asocian con una mayor incertidumbre en la volatilidad del ambiente (Hein, Fockert y Herrojo-Ruiz, 2021). Sin embargo, el hallazgo más llamativo de este modelo es que demostró que las creencias de las contingencias de las recompensas de personas con ansiedad tienen una menor incertidumbre, es decir, tienen distribuciones más estrechas y en consecuencia presentan una mayor resistencia a ser actualizadas (Hein et al., 2021).

Por otra parte, tratar a la ansiedad como unidimensional ha generado que muchas investigaciones tengan resultados contradictorios, pero una investigación reciente reveló que las personas con rasgos de ansiedad somática tienden a subestimar la incertidumbre relativa en el ambiente y eligen menos aleatoriamente sin importar la incertidumbre en la elección, en comparación de las personas con ansiedad cognitiva que no presentan cambios significativos en la exploración de las opciones respecto a individuos saludables (Fan, Gershman y Phelps, 2021). Este estudio representa un parteaguas para entender cómo se debe analizar la ansiedad de forma multidimensional y así esclarecer incongruencias en la literatura del tema, generando mejores tratamientos para el tipo de ansiedad que se tenga. Lo interesante también de esta investigación es que asumieron que los sujetos de estudio aproximaban como un observador Bayesiano ideal.

Así mismo, un modelo de aprendizaje por reforzamiento con un parámetro adicional que indica el grado de pesimismo en el agente, explica como el pesimismo conlleva a una excesiva propagación del miedo y la evitación de situaciones que se

encuentran incluso muy lejos del peligro, lo cual a su vez explica un amplio rango de comportamientos ansiosos como la exagerada evaluación de las amenazas, la generalización del miedo, la subestimación de la incertidumbre y una persistente evitación (Zorowitz et al., 2020). De igual forma, el modelo sirve como una formalización para explicar el rol de las creencias maladaptativas sobre el control y la autoeficacia en la ansiedad, no obstante hay que aclarar que el modelo no explica todos los tipos de ansiedad, pero sí explica los desórdenes de ansiedad que involucran aberraciones en los procesos cognitivos orientados al futuro como en la ansiedad generalizada y la ansiedad social (Zorowitz et al., 2020). Finalmente, hay que hacer énfasis en que este modelo se implementó con Inteligencia Artificial y no se hicieron pruebas con humanos, sino que se comparó la literatura existente con los resultados del agente virtual. Esto representa un gran paso en la psiquiatría computacional y la psicología computacional, ya que muestra el camino de cómo usar este tipo de herramientas en la investigación, aunque cabe recalcar que no son los primeros en hacerlo, pero sí de los primeros en ello.

Por último, es importante recordar que además de hacer investigación básica sobre la ansiedad, también es necesario investigar los tratamientos que se proponen para esta enfermedad y no sólo justificarlos con teoría en otras investigaciones, sino ver si la metodología genera resultados favorables. De hecho, hay tratamientos donde se han llegado a implementar algoritmos de aprendizaje por reforzamiento para que el propio paciente pueda evaluar el cambio en el valor esperado de ciertas conductas y así pueda ponderar cuál es la más óptima (Brewer, 2022). La investigación de Brewer y Roy (2021) muestra lo anterior al investigar como el entrenamiento en mindfulness para la ansiedad resulta más efectivo que la simple sustitución de conductas con ayuda de un algoritmo de aprendizaje por reforzamiento, debido a que la práctica de mindfulness desarrolla una mayor conciencia cognitiva, afectiva y física, así como que acompañado de una actitud hacia la curiosidad y el no juzgar las acciones y/o eventos permite desaprender más rápido ciclos de hábitos que perpetúan la ansiedad.

Al leer todo este apartado, es fácil ver la ventaja que representa el usar modelos computacionales para entender las enfermedades mentales, ya que estos brindan herramientas adicionales que permiten explicar los mecanismos detrás de ellas. Como todavía hay mucho que se necesita entender de la ansiedad y sería demasiado ambicioso querer explicar en un solo experimento todo, mejor se buscará dar respuesta a cómo el pesimismo puede afectar la evaluación de los estados en un ambiente más complejo que el usado por Zorowitz y sus colegas (usaron un ambiente simple de malla cuadrado), aludiendo a esto como un factor crucial de las personas con ansiedad, así como entender qué tanto el tipo de reforzamiento negativo impacta en la evaluación del agente.

4. Metodología

Se usó el modelo de Zorowitz et al (2020) para modelar la toma de decisiones de una gente ansiosa (pensimista) en un contexto de un Proceso de Decisión Markoviano. Las simulaciones se implementaron con el lenguaje de programación Python, utilizando la paquetería neuro-nav y el código está públicamente disponible en el siguiente link: https://github.com/Alicia-MJ/El_estudio_computacional_de_la_ansiedad_con_un_algoritmo_de_IA

Ambiente

Se usaron dos tipos de ambientes para evaluar las respuestas del agente y poder compararlas, el ambiente fue el mismo, solo que uno era grande y el otro pequeño, como se muestra en la figura 1. En cada ambiente se tuvieron solo dos estados que no eran 0, uno que daba una recompensa de 1 y otro aversivo que daba al agente un puntaje de -0.75 para la primera fase del experimento y de -1 para la segunda fase del experimento. El objetivo del agente es llegar al estado positivo (verde), aunque el agente en un inicio no conoce el entorno, por lo que lo tienen que ir explorando para encontrar la ruta óptima. Las posiciones iniciales de los cuadros verde, rojo y blanco se colocaron tratando de mantener una estructura lo más similar posible entre el entorno grande y el pequeño.




Figure 1. Entornos virtuales de neuro-nav: GridTopography.four_rooms. El cuadro blanco representa la posición inicial del agente, el verde la meta y el rojo un estado aversivo.

En estos entornos el agente tiene 4 acciones posibles: moverse a la derecha, izquierda, arriba o abajo. Además, cada episodio termina si pasa cualquiera de los siguientes casos: 1) el agente alcanza el número máximo de pasos temporales posibles 2) el agente llega al cuadro verde (obteniendo un puntaje de 1.0) y 3) si el agente junta un puntaje de -1.0 o superior.

Agente

Se utilizó el agente MBV de la librería neuro-nav, que es un algoritmo básico de iteración de valor, para replicar el modelo del agente de Zorowitz et al.(2020), el cual se sabe replica resultados de estudios de ansiedad con humanos. Por ello, cada agente se fijó con los siguientes parámetros:

- tasa de aprendizaje: 0.05
- política: egreedy (epsilon-greedy)
- epsilon: 0.25
- gamma: 0.95
- valores w (pesimismo): [1.0, 0.5, 0.0]

Nota: Se usaron tres agentes diferentes donde cada uno tenía un nivel de pesimismo (w) diferente: 1, 0.5 y 0, respectivamente. Esto para poder evaluar la

diferencia entre los resultados de cada agente. Los valores cercanos a 0 indican un nivel alto de pesimismo, mientras que los valores cercanos a 1 indican valores muy bajos de pesimismo.

El modelo matemático del agente es el siguiente (Zorowitz et al., 2020):

$$Q^w(s, a) = r(s, a) + \gamma \sum_{s'} p(s' | s, a) \left(w \max_{a'} Q^w(s', a') + (1 - w) \min_{a'} Q^w(s', a') \right)$$

Además, se configuró que todos los agentes tuvieran 100 episodios y un máximo de 150 pasos por episodio.

Fase 1 del experimento:

- *Objetivo:* Evaluar cómo el nivel de pesimismo-ansiedad en un agente impacta en la evitación y una errónea evaluación de estados no aversivos en el entorno four_rooms.
- *Hipótesis:* El agente elegirá el camino más largo a la meta conforme a mayor

Fase 2 del experimento:

- *Objetivo:* Evaluar cómo el nivel de aversión de un estado impacta en el aprendizaje y control cognitivo de un agente con diferentes niveles de pesimismo-ansiedad.
- *Hipótesis:* Entre mayor sea el nivel de aversión de un estado mayor impacto tendrá en el aprendizaje del agente, disminuyendo su control cognitivo.

5. Resultados

Como se puede ver en la figura 2 y la figura 3, los agentes con $w=1$ tienen una estimación más positiva de los estados del entorno, incluso los lejanos a la meta y los que son cercanos al estímulo aversivo. Así, como que alcanzan una mayor cantidad de veces la meta en comparación con los agentes con w igual a 0.5 y 0.0.

No obstante, una diferencia entre los agentes del entorno grande y del pequeño, es que el agente del entorno pequeño con $w = 0.5$ alcanza una mayor cantidad de veces la meta en comparación del agente del entorno grande con el mismo nivel de pesimismo. Adicionalmente, el agente en el entorno pequeño se aprecia que elige la ruta más larga desde que el nivel de pesimismo es 0.5, mientras que el agente con w igual a 0 mapea tres cuartos del área del entorno como aversivo.

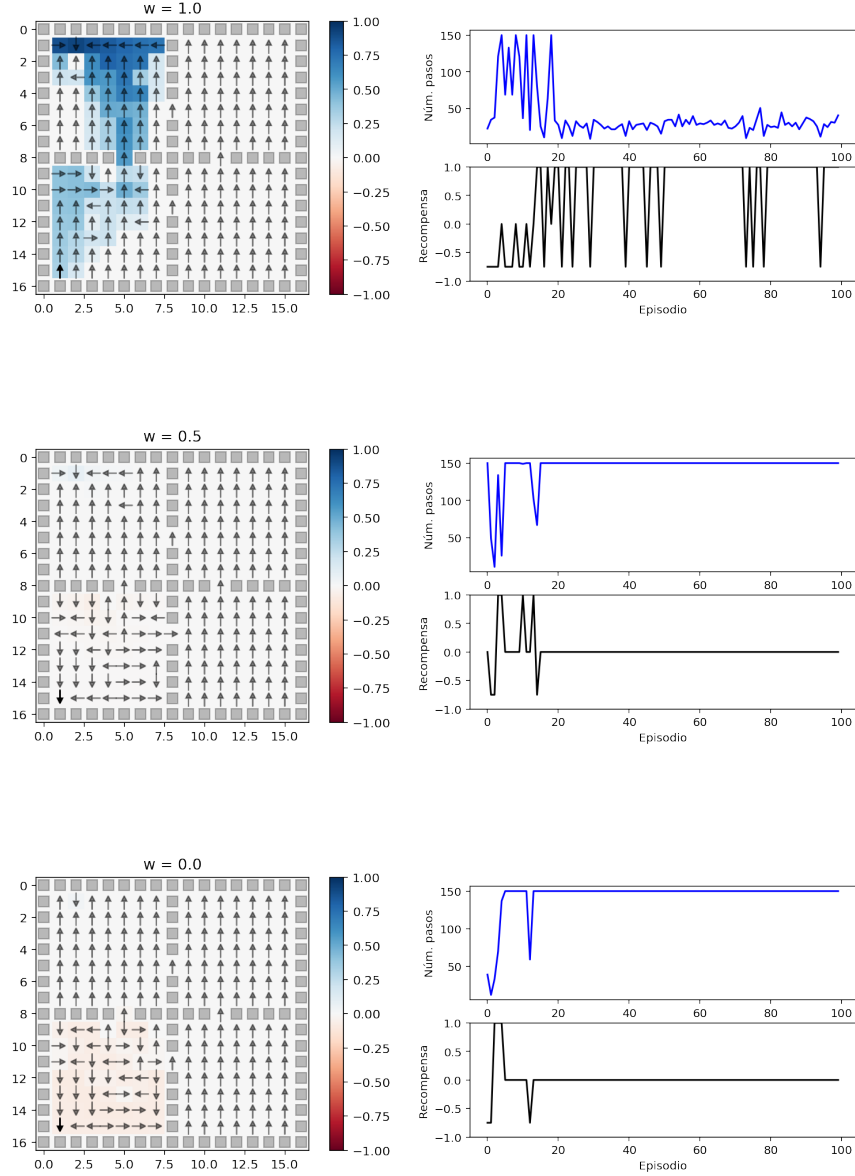


Figure 2. Resultados de la fase 1: mapas con los valores estimados de los estados en el entorno grande (imágenes de la izquierda) por agentes con valores w de 1, 0.5 y 0.0, respectivamente. Gráfica sobre el total de pasos en cada episodio (derecha superior) y la recompensa obtenida por episodio (derecha inferior).

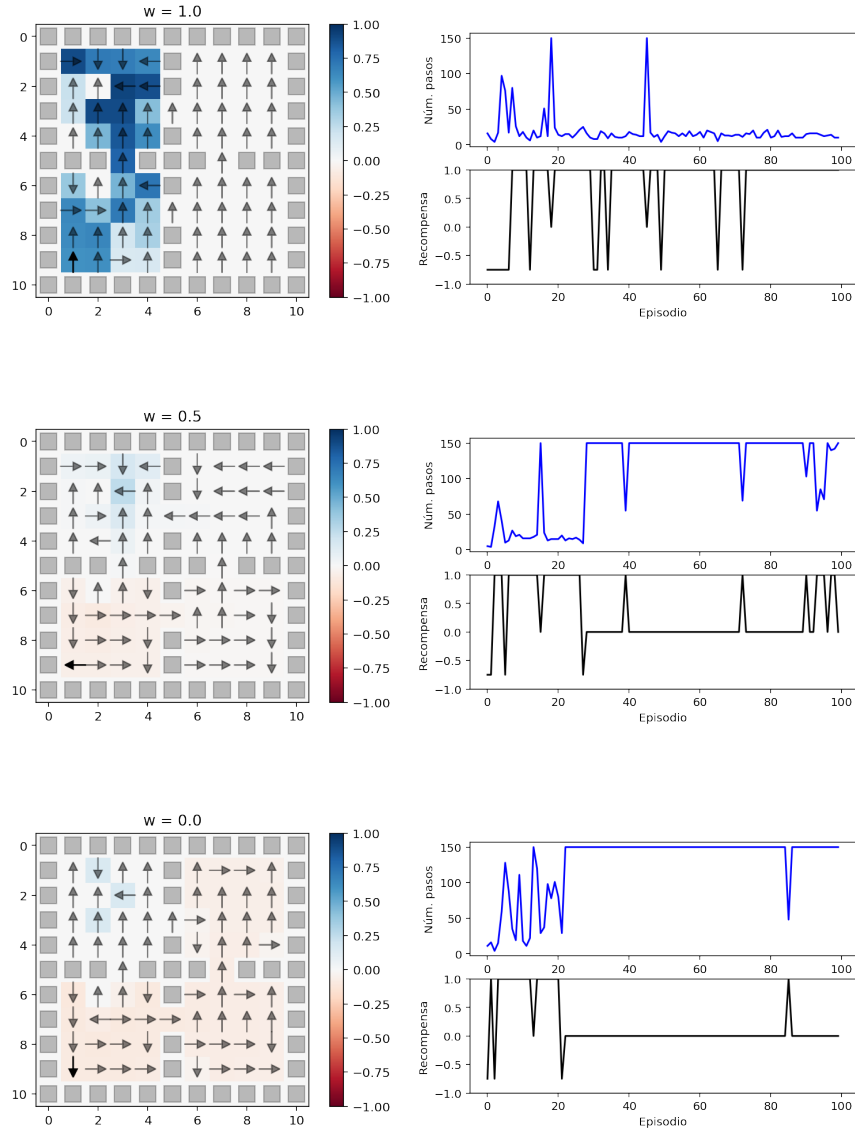


Figure 3. Resultados de la fase 1: mapas con los valores estimados de los estados en el entorno pequeño (imágenes de la izquierda) por agentes con valores w de 1, 0.5 y 0.0, respectivamente. Gráfica sobre el total de pasos en cada episodio (derecha superior) y la recompensa obtenida por episodio (derecha inferior) para cada agente

Como se aprecia en la figura 4, un estado aversivo que termine el episodio hace que un agente con un valor de w igual a 1 en el entorno grande estime como neutros la mayoría de estados, muy pocos como buenos e incluso estados cercanos al estado aversivo los clasifique como que hay que evitarlos. Sin embargo, un agente con el mismo valor w en el entorno pequeño en la fase dos del experimento no muestra una diferencia significativa respecto al agente en el entorno donde el estado aversivo

valía -0.75 (fase uno del experimento). Esto se replica en los mapas del entorno para todos los agentes en el entorno pequeño. Empero, si se analizan las gráficas del número de pasos por episodio y de las recompensas obtenidas por episodio para cada agente, se puede apreciar que el agente con $w=1$ en la fase dos aprende más rápido en comparación con el mismo agente en la fase 1. Así como que la relación se invierte con los agentes de $w=0$.

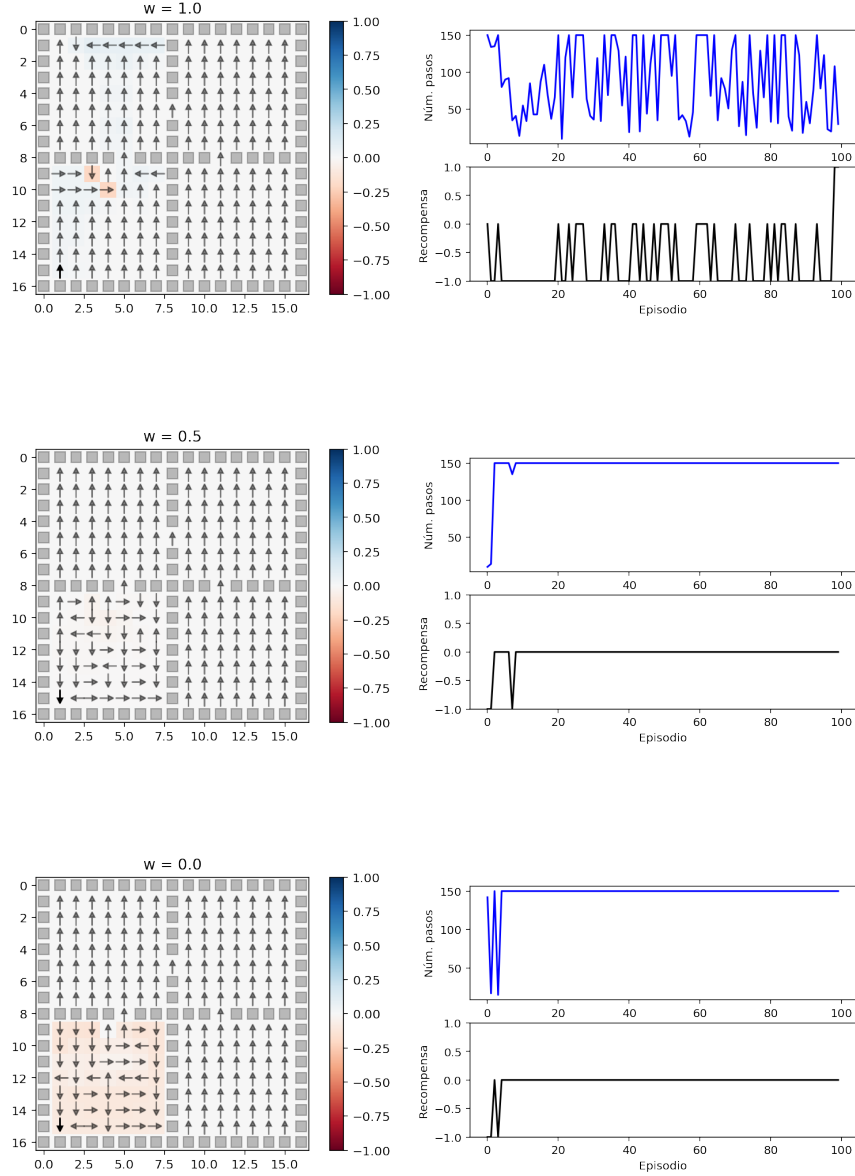


Figure 4. Resultados de la fase 2: mapas con los valores estimados de los estados en el entorno grande (imágenes de la izquierda) por agentes con valores w de 1, 0.5 y 0.0, respectivamente. Gráfica sobre el total de pasos en cada episodio (derecha superior) y la recompensa obtenida por episodio (derecha inferior).

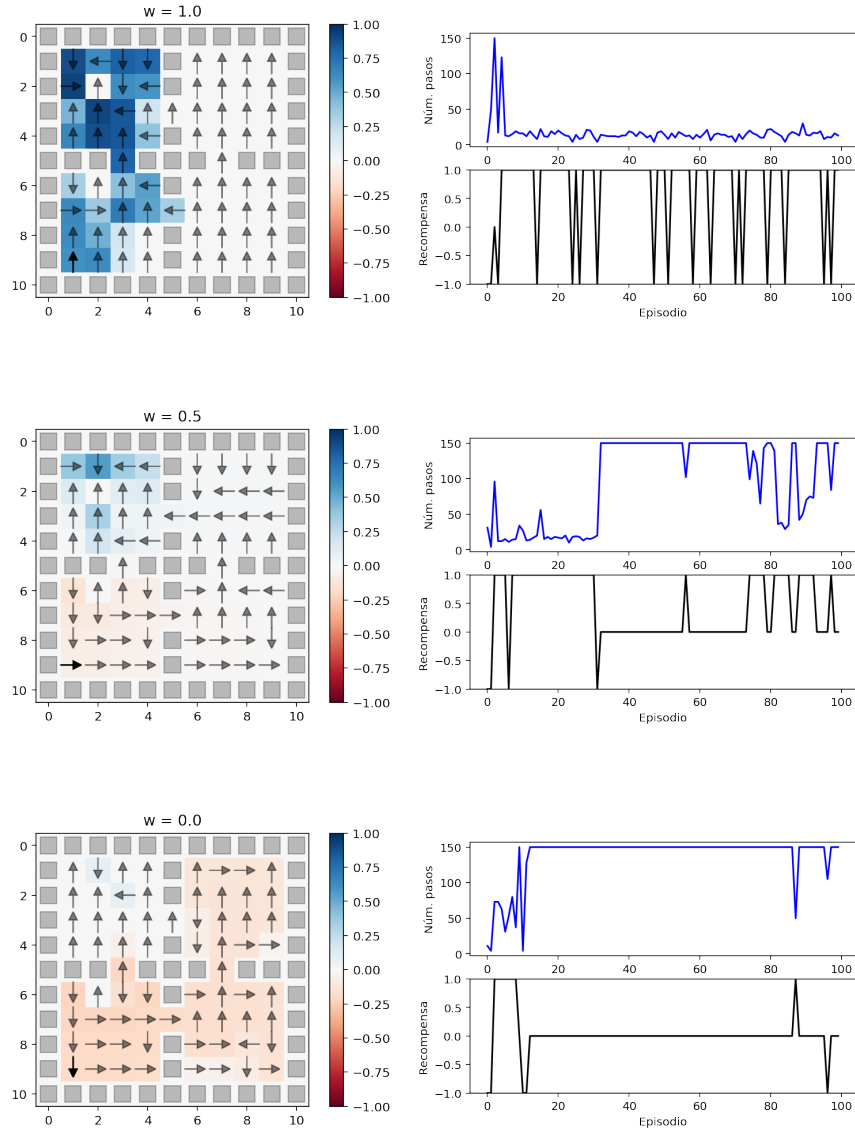


Figure 5. Resultados de la fase 2: mapas con los valores estimados de los estados en el entorno pequeño (imágenes de la izquierda) por agentes con valores w de 1, 0.5 y 0.0, respectivamente. Gráfica sobre el total de pasos en cada episodio (derecha superior) y la recompensa obtenida por episodio (derecha inferior) para cada agente

6. Discusión

El presente estudio examinó la relación del pesimismo con síntomas de la ansiedad como la evitación y una errónea evaluación de los diferentes estados del entorno four_room, tratando de dar explicación al impacto que tiene la cantidad de exploración, el nivel de pesimismo y el nivel del estado aversivo para la evaluación del agente del entorno, su toma de decisiones y su control cognitivo.

A través de dos fases experimentales se descubrió que la cantidad de exploración que tiene el agente (el número de pasos por episodio) impacta en la evaluación de los estados del entorno cuando el estado aversivo es absoluto y termina el episodio para el agente, en comparación de cuando el agente puede seguir explorando a pesar de haber pasado por el estado aversivo. Esto se concluyó debido a las diferencias en los resultados que se apreciaron entre los agentes que exploraron el entorno grande y los que exploraron el entorno pequeños. Por ejemplo, mientras los agentes en el entorno pequeño no muestran grandes diferencias respecto a la evaluación de los estados del ambiente cuando el estado aversivo es absoluto y cuando no lo es, los agentes del entorno grande sí muestran diferencias y esto se puede deber solo a que en el entorno grande 150 pasos por episodio no eran suficientes para explorar todo el ambiente, los cuales sí lo fueron para el entorno pequeño. Por lo tanto, se considera que si se aumentara el número de pasos por episodio para los agentes en el entorno grande se deberían de obtener resultados muy similares entre los dos tipos de entorno. Esto lleva a pesar cómo afecta la exploración para guiar la conducta y que una exploración limitada acompañada de estados aversivos con valores altos generará una errónea evaluación del ambiente para un agente no pesimista, el cual evalúa la mayoría de los estados como neutros, así como que presenta una mayor dificultad de encontrar la ruta óptima. Lo anterior, no se observa para agentes con w igual 0.5 o 0, lo cual se puede deber a que los agentes pesimistas en el entorno menos aversivo ya sobrestimaban el nivel de aversión, como si el estado aversivo fuera absoluto. Por ende, se puede concluir que el nivel del estado aversivo para agentes no pesimistas impacta en el aprendizaje de los agentes, su toma de decisiones y su control cognitivo, pero sólo cuando el agente no puede tener la exploración suficiente para cambiar su evaluación del ambiente. Finalmente, sería interesante para futuras investigaciones variar más la diferencia en la penalización del estado aversivo para ver cómo una menor penalización a las de este estudio afectan a los agentes.

Por otro lado, se descartó la hipótesis sobre que a mayor grado de pesimismo el

agente elegiría la ruta más larga a la meta, ya que se encontró que el agente con $w=0.5$ en el entorno pequeño sí elige la ruta más larga una considerable cantidad de veces, pero el agente con $w=0.0$ muy rara vez eligió la ruta más larga y, en cambio, la mayoría de veces no llegó a la meta, mostrando cómo el nivel de pesimismo resta al agente la capacidad de control para poder aprender de su ambiente. Como resultado, el agente aunque explore el entorno se ve limitado por su estimación del ambiente y tiende a sobreexplorar áreas conocidas, concordando con los resultados de Lamba et al. (2020). De igual forma, incluso aunque agentes con un valor $w = 0$ llegaron a la meta en una o más ocasiones en los primeros episodios, raramente volvían a llegar a la meta en los últimos episodios, mostrando la falta de control cognitivo en los agentes: a pesar de conocer una ruta para llegar a la meta casi nunca elegían ese camino. Es decir, los agentes pesimistas muestran menor flexibilidad para ajustarse a las demandas del ambiente, como resultado esto lleva a pensar que el pesimismo (una característica de las personas ansiosas) y no la ansiedad en sí es lo que genera una disminución la flexibilidad cognitiva de las personas (Wilson et al., 2018; Zorowitz et al., 2020). Esto puede considerarse como un indicador de que el pesimismo es un factor fundamental para el desarrollo de la ansiedad y síntomas de esta enfermedad, como la evitación, la sobreexploración de opciones conocidas, la sobreestimación de los estados aversivos en el entorno y una disminución en el control cognitivo (Grant et al., 2016; Zorowitz et al., 2020).

Por último, hay que recalcar que los resultados de este estudio coinciden con evidencia de otras investigaciones sobre desórdenes de ansiedad del tipo generalizado, ansiedad social o ansiedad somática (Lamba et al., 2020; Fan et al., 2022; Zorowitz et al., 2020). Esto se debe a que de antemano el modelo usado replicaba resultados de investigaciones sobre ansiedad generalizada y a nivel social, no obstante, el modelo ha ayudado a extender el entendimiento de la ansiedad sin la necesidad de correr el experimento en humanos, lo cual representa un punto muy fuerte para el uso de la Inteligencia Artificial en el campo de la psicología clínica, pero no sólo como algoritmos clasificadores, sino con agentes que simulan conductas para aprender más sobre los mecanismos cognitivos de las enfermedades mentales.

7. Limitaciones

Para estudios posteriores sería bueno poder reproducir el experimento con agentes humanos y ver si los resultados de este estudio se replican, aunque separando a los sujetos por nivel y tipo de ansiedad (somática y cognitiva), por lo planteado en el marco teórico.

8. Conclusiones

Este estudio mostró como el pesimismo da cuenta de varios síntomas altamente relacionados con la ansiedad y cómo el nivel de exploración impacta para la magnificación de estos síntomas: la evitación, una errónea evaluación de las amenazas, la sobreexploración y la falta de control cognitivo. Además, mostró cómo el usar la Inteligencia Artificial puede resultar como una herramienta sumamente útil para entender diferentes enfermedades mentales, como en este caso la ansiedad.

Referencias

- [1] AL ZOUBI, O. , MAYELI, A. , TSUCHIYAGAITO, A. , MISAKI, M., ZOTEV, V. , REFAI, H. , PAULUS, M., BODURKA, J. y TULSA 1000 INVESTIGATORS. (2019). EEG Microstates Temporal Dynamics Differentiate Individuals with Mood and Anxiety Disorders From Healthy Subjects. *Front. Hum. Neurosci.* 13 (56). doi: 10.3389/fnhum.2019.00056
- [2] BREWER, J. (2022). *Deshacer la Ansiedad*. Paidós.
- [3] BREWER, J. A. y ROY, A. (2021). Can Approaching Anxiety Like a Habit Lead to Novel Treatments? *American Journal of Lifestyle Medicine*, 15 (5), 489-494. doi: 10.1177/15598276211008144
- [4] COHEN, J. D. (2017). Cognitive Control: Core Constructs and Current Considerations. En T. Egner (ed.), *The Wiley Handbook of Cognitive Control* (pp. 127-142). Wiley Blackwell.

- [5] FAN, H., GERSHMAN, S. J., PHELPS, E. A. (2022). Trait somatic anxiety is associated with reduced directed exploration and underestimation of uncertainty. *Nat Hum Behav.* <https://doi.org/10.1038/s41562-022-01455-y>
- [6] GEDDERT, R. y EGNER, T. (2022). No Need to Choose: Independent Regulation of Cognitive Stability and Flexibility Challenges the Stability-Flexibility Trade-Off. *Journal of Experimental Psychology: General*, 151 (12). <https://doi.org/10.1037/xge0001241>
- [7] HEIN, T. P., DE FOCKERT, J. y HERROJO-RUIZ, M. (2020). State anxiety biases estimates of uncertainty and impairs reward learning in volatile environments. *NeuroImage*. <https://doi.org/10.1016/j.neuroimage.2020.117424>
- [8] KRAFT, D., RADEMACHER, L., ECKART, C. y FIEBACH, C. J. (2020). Cognitive, Affective, and Feedback-Based Flexibility – Disentangling Shared and Different Aspects of Three Facets of Psychological Flexibility. *Journal of Cognition*, 3(1): 21, 1–20. DOI: <https://doi.org/10.5334/joc.120>
- [9] LAMBA, A., FRANK, M. J. y FELDMANHALL, O. (2020). Anxiety Impedes Adaptive Social Learning Under Uncertainty. *Psychological Science*, 31(5), 592–603. DOI: 10.1177/0956797620910993
- [10] PIKE, A. C. y ROBINSON, O. (2022). A Reinforcement Learning in Patients With Mood and Anxiety Disorders vs Control Individuals. *JAMA Psychiatry*. doi:10.1001/jamapsychiatry.2022.0051
- [11] REMES, O., BRAYNE, C., VAN DER LINDE, R. y LAFORTUNE, L. (2016). A systematic review of reviews on the prevalence of anxiety disorders in adult populations. *Brain and Behavior*, 6 (7). <https://doi.org/10.1002/brb3.497>
- [12] SHARP, P. B. y ELДАР, E. (2019). Computational Models of Anxiety: Nascent Efforts and Future Directions. *Current Directions in Psychological Science*, 28(2), 170–176. <https://doi.org/10.1177/0963721418818441>
- [13] SMITH, R. , KUPLICKI, R. , FEINSTEIN, J. , FORTHMAN, K. L., STEWART, J. L. , PAULUS, M. P. , PAULUS, M., TULSA 1000 INVESTI-

- GATORS. y KHALSA, S. (2019). A Bayesian computational model reveals a failure to adapt interoceptive precision estimates across depression, anxiety, eating, and substance use disorders. *PLoS Comput Biol.* 16(12). <https://doi.org/10.1371/journal.pcbi.1008484>
- [14] SUMIYA, M. y KATAHIRA, K. (2020). Commentary: Altered learning under uncertainty in unmedicated mood and anxiety disorders. *Front. Hum. Neurosci.* 14 (561770). doi: 10.3389/fnhum.2020.561770
- [15] VAN STOCKUM, C. A. y DECARO, M. S. (2020). When working memory mechanisms compete: Predicting cognitive flexibility versus mental set. *Cognition*, 201. <https://doi.org/10.1016/j.cognition.2020.104313>
- [16] VERGUTS, T. (2017). Computational Models of Cognitive Control. En T. Egner (ed.), *The Wiley Handbook of Cognitive Control* (pp. 127-142). Wiley Blackwell.
- [17] VON WEGNER, F. , TAGLIAZUCCHI, E. y LAUFS, H. (2017).Information-theoretical analysis of resting state EEG microstate sequences - non-Markovianity, non-stationarity and periodicities. *NeuroImage*, 158, 99–111. <https://doi.org/10.1016/j.neuroimage.2017.06.062>
- [18] WEN, T. , GEDDERT, R. M. , MADLON-KAY, S. y EGNER, T. (2022).Transfer of learned cognitive flexibility to novel stimuli and task sets [preprint]. *bioRxiv*. doi: <https://doi.org/10.1101/2021.07.21.453253>
- [19] WILSON, C. G., NUSBAUM, A. T., WHITNEY, P. y HINSON, J. M. (2018). Trait anxiety impairs cognitive flexibility when overcoming a task acquired response and a preexisting bias. *PLoS ONE*, 13(9). <https://doi.org/10.1371/journal.pone.0204694>
- [20] ZOROWITZ, S., MOMENNEJAD, I. y DOW, N. D. (2020). Anxiety, avoidance, and sequential evaluation. *Comput Psychiatr.*, 4. doi:10.1162/cpsy_a_00026